


Raport z analizy PCA i HCA dla zbioru Wine

Celem analizy była eksploracja struktury zbioru danych Wine, określenie podobieństw między obiektami oraz ocena, w jakim stopniu zastosowane zmienne opisują zróżnicowanie próbek. W analizie wykorzystano dwie metody uczenia bez nadzoru: hierarchiczną analizę skupień (HCA) oraz analizę głównych składowych (PCA).

Analizę wykonano w programie Orange Data Mining. Przed obliczeniami zastosowano normalizację zmiennych, co było konieczne ze względu na różne skale cech. W analizie HCA porównywano obiekty (wiersze), stosując metrykę euklidesową. Następnie porównano trzy metody łączenia kłastrów: Average, Complete oraz Ward.

W analizie PCA wykorzystano wykres wariancji wyjaśnionej, wykres rozrzutu w układzie PC1–PC2 oraz macierz ładunków czynnikowych wyznaczoną za pomocą skryptu Python, zgodnie z wymaganiami ćwiczenia.

Analiza PCA wykazała, że pierwsza główna składowa (PC1) wyjaśnia około 36,2% wariancji, natomiast druga składowa (PC2) około 19,2%. Łącznie pierwsze dwie składowe opisują więc 55,4% całkowitej zmienności danych. Oznacza to, że projekcja dwuwymiarowa dobrze pokazuje główną strukturę zbioru, choć nie zawiera całej informacji.




Rys. 1 - wykres PC1/PC2

Na wykresie PC1–PC2 (Rys. 1) widoczne były trzy dość dobrze rozdzielone grupy, odpowiadające trzem klasom win. Klasa 1 znajdowała się głównie przy dodatnich wartościach PC1 i PC2, klasa 2 przy ujemnych wartościach PC2, natomiast klasa 3 przy ujemnych wartościach PC1 i dodatnich wartościach PC2. Można więc stwierdzić, że PC1 rozdziela głównie klasy 1 i 3, natomiast PC2 najlepiej odróżnia klasę 2 od pozostałych.

Interpretacja ładunków czynnikowych wykazała, że PC1 była dodatnio związana głównie ze zmiennymi Flavanoids, Total phenols, OD280/OD315, Proanthocyanins, Hue oraz Proline, a ujemnie z Malic Acid, Nonflavanoid phenols oraz Alkalinity of ash. Oznacza to, że składowa ta opisuje kontrast między winami o bogatszym profilu fenolowym a winami o wyższej zawartości kwasu jabłkowego i większej alkaliczności popiołu.

Z kolei PC2 była dodatnio związana przede wszystkim z Color intensity, Alcohol, Proline, Ash i Magnesium, a ujemnie głównie z Hue, co wskazuje, że odpowiada ona za różnice związane z intensywnością barwy i zawartością alkoholu. Na wykresie PCA nie zaobserwowano jednoznacznych, silnie odizolowanych obserwacji odstających.

Hierarchiczna analiza skupień potwierdziła obecność wyraźnej struktury grupowej w zbiorze Wine. Wszystkie porównywane metody łączenia wskazywały na istnienie kilku większych skupień, jednak najbardziej czytelny i zwarty wynik uzyskano dla metody Warda. Metoda Complete również pokazywała główne grupy, lecz dendrogram był mniej przejrzysty. Najmniej jednoznaczny wynik dała metoda Average, dla której połączenia między klastrami były bardziej rozciągnięte.



Rys. 2 - mapa odległości

Mapa odległości potwierdziła wyniki HCA. Na przekątnej widoczne były zwarte ciemniejsze bloki, co oznacza małe odległości między obiektami należącymi do tej samej grupy. Poza tymi blokami odległości były większe, co wskazuje na mniejsze podobieństwo między próbkami należącymi do różnych skupień.

Taki obraz potwierdza, że próbki nie są rozmieszczone przypadkowo, lecz tworzą grupy o podobnych właściwościach. Wynik ten jest zgodny zarówno z dendrogramami, jak i z wykresem PCA.

Podsumowując, wyniki PCA i HCA były ze sobą zgodne. Obie metody wskazały na obecność trzech głównych grup próbek, co oznacza, że zastosowane zmienne dobrze opisują zróżnicowanie zbioru. Ograniczeniem analizy jest jednak fakt, że pierwsze dwie składowe PCA wyjaśniają tylko 55,4% całkowitej wariancji, a wynik HCA zależy od doboru metryki odległości i metody łączenia klastrow. Mimo to uzyskane rezultaty jednoznacznie pokazują, że zbiór Wine ma uporządkowaną strukturę i może być skutecznie analizowany metodami eksploracji danych wielowymiarowych.